BMA
BARCELONA
MARKET ANALYTICS

Proyecto Integrador:
Mercado turístico de Airbnb en Barcelona (2025)

Python | SQL | Power BI



Equipo de Consultoría:

- Martina Cottura
- Fernando Ferrari
- Andrea Marques
- Mario Paoloni

Índice

1. Introducción..... 4
1.1. Presentación del cliente..... 4
1.2. Problema de negocio y contexto actual..... 4
1.3. Rol de la consultora Barcelona Market Analytics (BMA)..... 5
1.4. Pregunta general de negocio y árbol de preguntas..... 5
2. Objetivos del proyecto..... 6
2.1. Objetivo general..... 6
2.2. Objetivos específicos..... 6
3. Comprensión del mercado y preparación de datos..... 6
3.1. Reunión inicial con stakeholders..... 6
3.2. Preguntas analíticas operativas..... 7
3.3. Datos disponibles y alcance..... 7
4. Metodología..... 8
5. Resultados esperados..... 8
6. Procesamiento y preparación de datos en Python..... 8
6.1. Entorno tecnológico utilizado..... 9
6.2. Pipeline de procesamiento de datos..... 9
6.3. Fuentes de datos procesadas..... 10
6.4. Procesamiento del dataset Listings..... 10
6.5. Procesamiento del dataset Calendar..... 12
6.6. Procesamiento del dataset Neighbourhoods..... 13
6.7. Resumen de transformaciones realizadas..... 13
6.8. Resultados de la preparación de datos..... 14
7. Modelado de datos en SQL..... 14
7.1. Introducción..... 14
7.2. Modelo de datos propuesto..... 14
7.3. Flujo de datos..... 15
7.4. Data Definition Language..... 16
7.5. Data Manipulation Language..... 17
7.6. Validación de integridad de datos..... 19
7.7. Diagrama de Entidad-Relación, ERD..... 19
7.8. DUMP del script..... 21
8. Análisis y visualización en PowerBI..... 21
8.1. Introducción..... 21
8.2. Conexión SQL - PowerBI..... 21
8.3. Modelo de datos..... 22
8.4. PowerQuery..... 23
8.5. Medidas DAX..... 23
8.6. Estructura del dashboard..... 27
8.7. KPIs y valores registrados (scraping 14 sep 2025)..... 31

8.8. Insights relevantes..... 32
9. Conclusiones.....33
9.1. Oportunidades y riesgos..... 33
9.2. Recomendaciones estratégicas a futuro para MUI..... 33
9.3. Sugerencias para análisis futuros..... 34
10. Anexo..... 35
10.1. Diccionario de datos.....35
10.2. Gestión del proyecto: GANTT..... 38

Informe técnico:

Análisis del mercado de viviendas turísticas en Airbnb

Caso: Barcelona 2025

1. Introducción

1.1. Presentación del cliente

Mediterranean Urban Investments (MUI) es una empresa de inversión inmobiliaria especializada en mercados urbanos del mediterráneo. La compañía busca identificar oportunidades y riesgos en el mercado de viviendas de uso turístico en Barcelona, con el objetivo de optimizar decisiones estratégicas de inversión.

MUI requiere comprender cómo los cambios regulatorios recientes afectan la oferta, los niveles de precios y la concentración de anuncios en la plataforma Airbnb, con el fin de orientar decisiones hacia barrios estratégicos y evaluar los riesgos asociados a la concentración de la oferta y el cumplimiento normativo.

1.2. Problema de negocio y contexto actual

El mercado de viviendas de uso turístico en Barcelona opera en un entorno altamente restrictivo, consolidado por más de una década de política regulatoria y agudizado en 2025 por dinámicas recientes de mercado.

Marco regulatorio vigente:

El **PEUAT** (Plan Especial de Alojamientos Turísticos) zonifica la ciudad según niveles de restricción para equilibrar el turismo y el uso residencial. Desde 2014, Barcelona no concede nuevas licencias de vivienda turística, lo que limita estructuralmente la expansión de la oferta legal. A esto se suma un control reforzado sobre las plataformas digitales, que deben verificar licencias y retirar anuncios ilegales en un plazo máximo de 48 horas bajo requerimiento municipal[1].

[1] Ajuntament de Barcelona. *Revisión PEUAT*. Dirección de Turismo del Ayuntamiento de Barcelona. Consultado en marzo de 2025. Disponible en: https://ajuntament.barcelona.cat/turisme/es/revision-peuat

En este contexto, el análisis de precios, disponibilidad y cumplimiento normativo por barrio se convierte en una ventaja competitiva decisiva para identificar dónde invertir con seguridad y maximizar el retorno.

1.3. Rol de la consultora Barcelona Market Analytics (BMA)

Barcelona Market Analytics (BMA) es la consultora responsable del análisis encargado por MUI. Su intervención responde a la necesidad del cliente de contar con información cuantificable y accionable sobre el mercado de Airbnb en Barcelona, que permita orientar decisiones de inversión con base empírica.

En el marco de este proyecto, BMA asume las siguientes responsabilidades:

Analizar los datos públicos de Inside Airbnb correspondientes a Barcelona 2025, detectar patrones de oferta, concentración de anfitriones y estructura de precios, e identificar el nivel de cumplimiento normativo por barrio. A partir de estos hallazgos, el equipo de Data Analytics de BMA —especializado en mercados urbanos y plataformas digitales— traducirá los resultados en insights estratégicos y recomendaciones de inversión orientadas a MUI.

1.4. Pregunta general de negocio y árbol de preguntas

Pregunta de negocio principal:

¿Cuál es la dimensión y composición actual del mercado de viviendas de uso turístico de Airbnb en Barcelona en términos de volumen, precios, tipología de alojamiento y nivel de cumplimiento normativo?

Árbol de preguntas estratégicas:

Para estructurar el análisis, la pregunta de negocio se descompone en cinco dimensiones analíticas:

- *Distribución de la oferta:* ¿Cómo se distribuyen los anuncios por barrio? ¿Qué barrios concentran más operadores?
- *Tipología de alojamiento:* ¿Qué tipos de alojamiento predominan? ¿Cómo varía la tipología según la zona?
- *Concentración de anfitriones:* ¿Qué proporción de *host* administra múltiples anuncios? ¿Cómo se relaciona esa concentración con los precios y el cumplimiento normativo?
- *Disponibilidad y patrones temporales:* ¿Qué períodos muestran mayor disponibilidad? ¿Existen patrones estacionales diferenciados por barrio?
- *Estructura de precios:* ¿Cómo se distribuyen los precios según tipología y barrio? ¿Qué factores podrían indicar oportunidades de inversión o riesgo regulatorio?

Este árbol de preguntas conecta la pregunta de negocio con el análisis de datos, mostrando a los stakeholders cómo cada dimensión aporta insights estratégicos accionables.

2. Objetivos del proyecto

2.1. Objetivo general

Realizar un análisis descriptivo del mercado de viviendas turísticas en Airbnb en Barcelona (2025), centrado en la distribución de la oferta, la estructura de precios, los patrones de disponibilidad, las características de los anfitriones y el nivel de cumplimiento normativo, con el fin de apoyar las decisiones estratégicas de inversión de MUI.

2.2. Objetivos específicos

- Analizar la distribución espacial de los anuncios por barrio y zona administrativa.
- Identificar la tipología de alojamiento predominante y su variación geográfica.
- Evaluar los patrones de disponibilidad temporal y estacionalidad del mercado.
- Determinar el grado de concentración y profesionalización de los anfitriones.
- Analizar la distribución de precios según tipología, barrio y estado regulatorio.
- Evaluar el nivel de cumplimiento normativo en materia de licencias turísticas.
- Traducir los hallazgos en recomendaciones estratégicas de inversión para MUI.

3. Comprensión del mercado y preparación de datos

3.1. Reunión inicial con stakeholders

Con el objetivo de garantizar que el análisis respondiera directamente a las necesidades estratégicas del cliente, se realizaron reuniones de relevamiento con MUI en la etapa inicial del proyecto. En estas instancias se aplicaron entrevistas semiestructuradas que permitieron definir las expectativas y prioridades del análisis, identificar los riesgos y oportunidades considerados críticos por el cliente, y establecer entregables claros y accionables alineados con los objetivos de inversión de la compañía.

Los acuerdos alcanzados en estas reuniones constituyeron el marco de referencia para orientar las decisiones metodológicas y analíticas del proyecto.

3.2. Preguntas analíticas operativas

A partir de los acuerdos con MUI y del árbol de preguntas estratégicas definido en el inciso 1.4, se operacionaliza la pregunta de negocio en tres preguntas analíticas concretas que guían el análisis de datos y la interpretación de resultados:

- ¿Cómo se distribuye la oferta territorialmente y qué tipología de alojamiento predomina por zona?
- ¿Qué grado de concentración y profesionalización presenta el mercado, y cómo se relaciona con los precios y el cumplimiento normativo?
- ¿Qué patrones temporales de disponibilidad se observan entre septiembre de 2025 y septiembre de 2026?

Estas preguntas aseguran que cada hallazgo del análisis tenga relevancia estratégica directa para MUI.

3.3. Datos disponibles y alcance

Fuente de datos

Los datos provienen de Inside Airbnb[2], un repositorio público que recopila información de anuncios de Airbnb mediante técnicas de web scraping ético. Los datasets utilizados contienen información sobre tipo de alojamiento, precio listado, valoraciones, disponibilidad, barrio, coordenadas aproximadas, características del anfitrión y estado de la licencia turística. La muestra analizada comprende más de 19.000 anuncios en Barcelona, correspondientes al scraping realizado en septiembre de 2025.

Alcance del análisis

El estudio consiste en un análisis descriptivo transversal, es decir, una fotografía del mercado en un momento específico. Este enfoque permite analizar la estructura del mercado de alquiler turístico, la distribución geográfica de la oferta, la estructura base de precios, las estrategias de disponibilidad de los anfitriones y el nivel de cumplimiento normativo.

Limitaciones

El análisis refleja oferta declarada, no demanda real. La disponibilidad registrada no equivale a ocupación efectiva. Los precios no incorporan dinámicas de temporada ni ajustes dinámicos. Los datos provienen de una fuente de terceros y no son oficiales de Airbnb. El análisis se limita a la plataforma Airbnb y no contempla otras plataformas de alquiler turístico.

---

[2] Inside Airbnb. *Get the Data*. Housing Justice Data Lab. Consultado en marzo de 2025. Disponible en: https://insideairbnb.com/get-the-data/

4. Metodología

El proyecto siguió un enfoque de análisis descriptivo, seleccionado por su adecuación al objetivo de caracterizar el estado actual del mercado sin inferir causalidades ni proyectar tendencias futuras. Este tipo de estudio permite sintetizar grandes volúmenes de datos en indicadores comprensibles y accionables para la toma de decisiones de inversión.

El proceso metodológico se organizó en cuatro etapas secuenciales. En primer lugar, la **preparación de datos**, que incluyó la limpieza, verificación de consistencia y transformación de los tres datasets fuente (listings, calendar y neighbourhoods), asegurando su integridad antes del modelado. En segundo lugar, el **modelado de datos**, mediante la construcción de un esquema dimensional en SQL que estructuró la información en tablas de hechos y dimensiones, optimizando las consultas analíticas. En tercer lugar, el **análisis descriptivo**, centrado en la distribución de anuncios por barrio y tipología, la concentración de anfitriones, los patrones de disponibilidad temporal y la estructura de precios de anuncios activos con licencia. Finalmente, la **interpretación estratégica y visualización**, orientada a traducir los hallazgos en insights accionables mediante un dashboard interactivo en Power BI, diseñado para facilitar la toma de decisiones por parte de los stakeholders de MUI.

5. Resultados esperados

El análisis tiene como propósito entregar a MUI una visión integral y cuantificada del mercado de viviendas turísticas en Barcelona, estructurada en torno a las dimensiones definidas en los objetivos del proyecto.

Se espera identificar los barrios con mayor concentración de anuncios y aquellos con mayor rentabilidad potencial por escasez de oferta, detectar el perfil y grado de profesionalización de los operadores del mercado, caracterizar las tipologías de alojamiento predominantes por zona, describir los patrones de disponibilidad a lo largo del período analizado, y evaluar el nivel de cumplimiento normativo en materia de licencias turísticas.

Los resultados serán presentados con un enfoque visual e interpretativo, priorizando la claridad para perfiles no técnicos y la utilidad directa para decisiones de inversión inmobiliaria en Barcelona.

6. Procesamiento y preparación de datos en Python

El detalle del proceso de preparación y limpieza de los datos se encuentra documentado paso a paso en los archivos Jupyter Notebook que acompañan este informe (`listings.ipynb`, `calendar_limpio_filtrado.ipynb` y `neighbourhoods.ipynb`).

A continuación se mencionan los criterios técnicos y las decisiones tomadas al analizar cada dataset mediante el procesamiento y preparación de datos en Python.

6.1. Entorno tecnológico utilizado

El procesamiento y preparación de los datos se realizó utilizando Python en entorno de notebooks (Jupyter/Anaconda), lo que permitió desarrollar un flujo de trabajo reproducible para la exploración, transformación y validación de los datasets. La biblioteca principal utilizada fue pandas, ampliamente empleada en proyectos de análisis de datos por su eficiencia en la manipulación de estructuras tabulares.

Herramienta	Función
Python	Lenguaje principal para procesamiento de datos
Pandas	Manipulación y transformación de datasets
Jupyter / Anaconda	Desarrollo de notebooks de análisis
CSV	Formato de exportación de datos para carga en SQL

El uso de notebooks permitió documentar paso a paso las transformaciones realizadas y facilitar la trazabilidad del proceso de preparación de datos.

6.2. Pipeline de procesamiento de datos

El flujo completo de datos implementado en el proyecto sigue una arquitectura secuencial desde la extracción de datos hasta su explotación analítica:

Bases de datos de Inside Airbnb (Septiembre 2025)

↓

Exploración y limpieza en Python

↓

Transformación y creación de variables

↓

Generación de datasets limpios

↓

Carga en tablas staging (SQL)

↓

Modelo dimensional

↓

Visualización analítica en Power BI

Esta arquitectura permite separar claramente las etapas de preparación de datos, modelado de datos y análisis de negocio, siguiendo buenas prácticas de ingeniería de datos.

6.3. Fuentes de datos procesadas

El procesamiento en Python se realizó sobre tres datasets principales obtenidos mediante scraping de Airbnb en septiembre de 2025.

Listings — Contiene información estructural de los anuncios publicados en la plataforma, incluyendo características del alojamiento, información del anfitrión, ubicación, precios y regulaciones asociadas a licencias turísticas. Este dataset constituye la base del análisis del mercado.

Calendar — Contiene información de disponibilidad diaria para cada anuncio, donde cada registro representa la combinación anuncio + fecha. Permite analizar la evolución temporal de la disponibilidad y estudiar la intensidad temporal del mercado turístico.

Neighbourhoods — Contiene la correspondencia entre los barrios de Barcelona y sus zonas administrativas, y permite estructurar el análisis territorial de la oferta.

6.4. Procesamiento del dataset Listings

El dataset de anuncios constituye la tabla central del sistema analítico, ya que contiene la información estructural de cada alojamiento. El procesamiento incluyó las siguientes etapas.

Exploración inicial

Se realizó una inspección preliminar mediante las funciones **`head()`**, **`info()`**, **`describe()`** y un análisis de valores nulos. Esto permitió identificar tipos de datos incorrectos, columnas irrelevantes y variables con valores faltantes.

Selección de variables relevantes

A partir del análisis exploratorio (EDA) se seleccionaron las variables necesarias para el proyecto: identificador del anuncio, identificador del host, barrio, tipo de alojamiento,

capacidad del alojamiento, precio, noches mínimas y máximas, valoraciones y licencia turística. Esta selección permitió reducir la complejidad del dataset original.

Limpieza y normalización de datos

Se aplicaron las siguientes transformaciones para asegurar la consistencia de los datos. La variable `price` se encontraba en formato texto con símbolo monetario y separadores de miles; se eliminaron los caracteres no numéricos y se convirtió a formato numérico `float64`. La variable `last_scraped` fue transformada a formato `datetime64` para habilitar análisis temporales. Las variables `host_listings_count` y `host_total_listings_count`, almacenadas originalmente como `float64`, fueron convertidas a `int32` al no contener decimales ni valores nulos tras la limpieza.

Creación de variables derivadas

Se generaron tres variables adicionales que enriquecen el análisis. La variable `precio_por_persona` se calculó como `precio / accommodates`, permitiendo comparar alojamientos con diferentes capacidades. La variable `tipo_host` clasifica a los anfitriones en *Individual* (un único anuncio) o *Professional* (dos o más anuncios), con base en el número total de anuncios gestionados. La variable `tipo_licencia` categoriza cada anuncio en *Licensed*, *Exempt* o *Sin licencia*, permitiendo analizar el grado de cumplimiento regulatorio del mercado.

Análisis de valores faltantes

Se evaluaron las variables con valores nulos, especialmente precio, licencia y valoraciones. Se identificó que una proporción significativa de anuncios no presenta precio informado, lo que puede estar relacionado con configuraciones específicas del calendario o anuncios temporalmente inactivos.

Análisis de disponibilidad del anuncio

Se analizó la variable de disponibilidad anual (`availability_365`) y se detectó un subconjunto de anuncios con disponibilidad igual a cero. Tras evaluar su comportamiento se decidió mantener estos registros en el dataset, dado que pueden representar calendarios completamente reservados, anuncios temporalmente inactivos o configuraciones específicas del anfitrión.

Análisis de valores extremos

Se evaluaron valores extremos en las variables precio, noches mínimas y precio por persona mediante el método del rango intercuartílico (IQR). Los valores extremos no fueron eliminados, ya que representan comportamientos reales del mercado.

Generación del dataset final

Tras completar todas las transformaciones se generó el archivo `listings_clean.csv`, utilizado posteriormente para la carga en la capa de staging de la base de datos.

6.5. Procesamiento del dataset Calendar

El dataset calendar contiene información de disponibilidad diaria de los anuncios, cubriendo el período comprendido entre el 14/09/2025 y el 14/09/2026. Debido a su granularidad temporal, este dataset es considerablemente más grande que el de anuncios, ya que cada registro representa la combinación `id_anuncio + fecha`.

Exploración inicial y transformaciones realizadas

Se realizó una inspección preliminar para identificar tipos de datos incorrectos, columnas irrelevantes y valores inconsistentes. Las principales transformaciones aplicadas fueron la conversión de la variable `date` a formato `datetime`, que permitió determinar el rango de disponibilidad diaria y habilitar análisis temporales posteriores; la limpieza de las variables `noches_minimas` y `noches_maximas`, ajustando valores extremos y corrigiendo inconsistencias detectadas; y la eliminación de duplicados y columnas vacías (`price` y `adjusted_price`), utilizando la variable precio del dataset `listings_clean` como referencia de precios.

Análisis de valores extremos en noches

Se evaluaron los valores extremos en las variables de noches mínimas y máximas. En noches mínimas se identificaron 135.133 registros con valores iguales o superiores a 75 noches, llegando hasta 365, representando anuncios orientados a estadías largas. En noches máximas se identificaron 726 registros con un valor de 3.650 noches, correspondientes a límites máximos establecidos por defecto en la plataforma. Al igual que en listings, estos valores no fueron eliminados por representar comportamientos reales del mercado.

Adaptación para compatibilidad con MySQL

Se adaptaron los tipos de columnas para asegurar la compatibilidad directa con MySQL y facilitar la carga mediante `LOAD DATA`. Las variables `id_anuncio`, `disponible`, `noches_minimas` y `noches_maximas` fueron convertidas a tipo `INT`, y la variable `fecha` fue convertida a formato string en notación `YYYY-MM-DD` para que MySQL la interprete automáticamente como tipo `DATE`.

Filtrado de anuncios válidos

Para mantener la consistencia del modelo analítico, el dataset calendar fue filtrado para conservar únicamente los registros asociados a anuncios presentes en `listings_clean`. Tras aplicar este filtrado se validó que ambos datasets contuvieran la misma cantidad de anuncios activos: 16.676 anuncios, garantizando así la integridad referencial entre ambas tablas antes de su carga en SQL.

Análisis de cobertura temporal

Se verificó el rango de fechas registradas por anuncio. El dataset filtrado contiene 6.086.742 filas frente a las 6.086.740 esperadas (16.676 × 365), diferencia atribuible a 4 anuncios con 366 días registrados, probablemente por registros adicionales en los extremos del período. Dado que esta diferencia no afecta las métricas globales, se decidió mantener dichos registros.

Generación del dataset final

Tras completar todas las transformaciones, el dataset quedó compuesto por 6.086.742 filas y 5 columnas. El resultado fue exportado como `calendar_limpio_filtrado.csv`, archivo utilizado posteriormente para poblar la tabla `staging_calendar` en la base de datos.

6.6. Procesamiento del dataset Neighbourhoods

El dataset neighbourhoods contiene la información territorial de los barrios de Barcelona. Las transformaciones realizadas incluyeron la normalización de nombres de barrios, la verificación de correspondencia con el dataset de anuncios y la preparación del dataset para su uso como dimensión territorial en el modelo analítico. El resultado fue exportado como **`neighbourhoods_clean.csv`.**

6.7. Resumen de transformaciones realizadas

Dataset	Transformaciones principales
listings	Limpieza de precios, conversión de fechas, conversión de tipos de datos, creación de variables derivadas, análisis de valores faltantes y extremos
calendar	Conversión de fechas, filtrado de anuncios válidos, adaptación de tipos para MySQL

neighbourhoods	Normalización territorial y validación de correspondencia con listings

6.8. Resultados de la preparación de datos

Tras completar el procesamiento en Python se generaron tres datasets finales listos para su integración en el modelo analítico:

Dataset	Descripción
`listings_clean.csv`	Información estructural de los anuncios
`calendar_limpio_filtrado.csv`	Disponibilidad diaria por anuncio
`neighbourhoods_clean.csv`	Información territorial

Estos archivos constituyen la base de la capa de staging utilizada posteriormente en el modelo de datos desarrollado en SQL. La fase de preparación en Python permitió transformar los datos crudos en datasets estructurados, consistentes y compatibles con el modelo dimensional, sentando las bases para la construcción de la arquitectura analítica en SQL y el desarrollo del dashboard en Power BI.

7. Modelado de datos en SQL

7.1. Introducción

Una vez realizada la limpieza de los datos en Python, se ha procedido con el modelado y creación de tablas en MySQL Workbench. Esta etapa del proyecto tiene como objetivo transformar los archivos CSV ya limpios, en una arquitectura de datos estructurada, normalizada y optimizada para una posterior visualización de resultados en Power BI.

7.2. Modelo de datos propuesto

Para el análisis del mercado Airbnb se adoptó un modelo dimensional basado en un esquema tipo estrella, *Star Schema*, debido a sus múltiples ventajas:

- Consultas analíticas más rápidas
- Reducción de redundancia de información
- Estructura intuitiva para análisis de negocio

- Mayor eficiencia en herramientas de visualización

Este modelo dimensional trabaja con tablas de hechos, las cuales contienen métricas medibles; y tablas de dimensiones, las cuales describen el contexto de las métricas.

Conociendo ya nuestros datos, provenientes de la limpieza inicial en Python, hemos decidido tener como tablas de hechos:

1. fact_anuncios
2. fact_disponibilidad

Así como trabajar con las siguientes tablas de dimensiones:

1. dim_host
2. dim_barrio
3. dim_tipo_alojamiento
4. dim_tipo_licencia

La razón por la cual se ha decidido utilizar dos tablas de hechos en lugar de una es debido a que tenemos 2 procesos de negocio distintos:

- Por una parte, tenemos la oferta de anuncios: **listings**
- Por otra parte, tenemos la disponibilidad en el tiempo: **calendar**

Cada una de ellas tiene: granularidad distinta, métricas distintas y frecuencia distinta.

Entendiendo por granularidad el nivel de detalle del dato, se convierte en un concepto clave para esta decisión del proyecto, y dará respuesta a la siguiente pregunta: ¿qué representa una fila?

Para fact_anuncios, la granularidad es:

1 fila = 1 anuncio

Pues se debe a la foto estática del mercado, el dia del scraping de los datos.

Para fact_disponibilidad, la granularidad es:

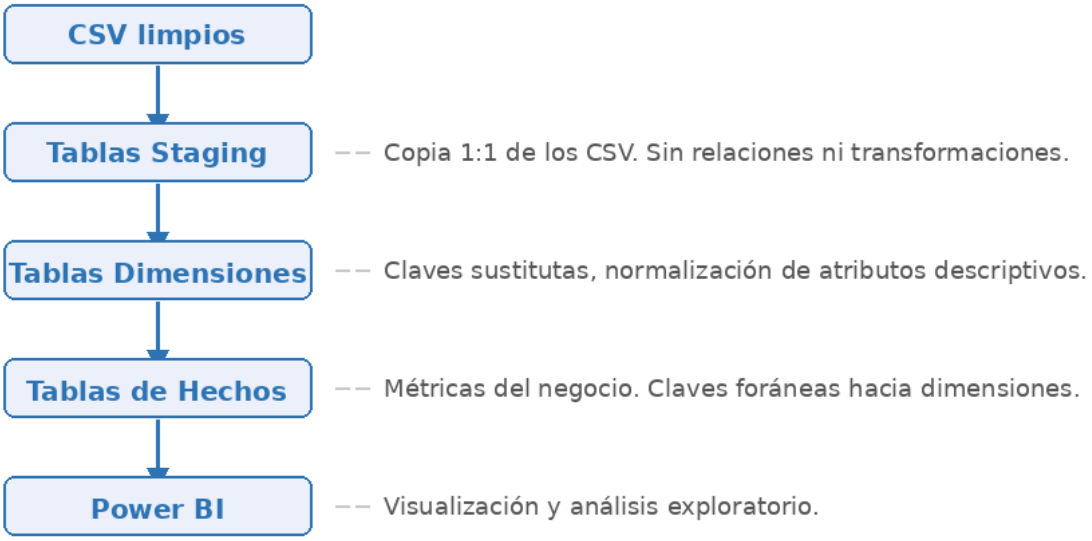
1 fila = 1 anuncio × 1 día

Pues contendrá la proyección de todos los anuncios, todos los días durante el año de análisis.

Como se ha decidido incluir más de una tabla de hechos, el modelo completo puede interpretarse como una constelación de hechos (*fact constellation schema*).. En este caso, las tablas fact_anuncios y fact_disponibilidad permiten analizar el mercado desde dos niveles de granularidad distintos: el estado estructural de los anuncios y la evolución temporal de su disponibilidad.

7.3. Flujo de datos

Teniendo definido el modelo de datos que se quiere conseguir, se ha seguido el flujo de datos representado a continuación:



De esta forma, se ha procedido con el DDL, *Data Definition Language*, para crear la base de datos, crear las tablas de dimensiones y hechos, y definir las claves primarias y foráneas. Posteriormente se procederá con el DML, *Data Manipulation Language*, para cargar y manipular los datos, que permitirá una transformación y normalización de los datos.

Como se puede observar en el flujo propuesto, antes de crear las tablas de dimensiones y hechos, se han creado unas tablas *staging*, que consistirán en tablas crudas, una copia 1:1 de los CSV limpios. Con estas tablas no se pretende modelar ni relacionar, sino guardar los datos tal como vienen; y tienen como objetivo evitar la repetición de datos, y validar la integridad antes de realizar transformaciones, evitando que posibles errores en los datos fuente afecten directamente al modelo analítico.

7.4. Data Definition Language

El paso a paso seguido para construir la estructura de nuestro modelo, se detalla a continuación, mencionando las líneas del script de SQL. Por su parte, el script de SQL también cuenta con comentarios explicativos de todos los pasos que se ejecutan.

1. Creación de la base de datos → línea 6: CREATE DATABASE
2. Selección de base de datos creada → línea 8: USE
3. Creación de tablas staging: CREATE TABLE
    a. staging_listings → líneas 16-40
    b. staging_calendar → líneas 47-55
    c. staging_neighbourhoods → líneas 62-67

4. Creación de tablas de dimensiones: CREATE TABLE
    a. dim_host → líneas 74-80
    b. dim_barrio → líneas 88-95
    c. dim_tipo_alojamiento → líneas 102-106
    d. dim_tipo_licencia → líneas 113-116
5. Creación de tablas de hechos: CREATE TABLE
    a. fact_anuncios → líneas 123-147
    b. fact_disponibilidad → líneas 154-163

Algo que destacar de las tablas de dimensiones, es la creación de las claves sustitutas, id_barrio, id_tipo_alojamiento, id_tipo_licencia, que son auto-incrementales, y se utilizan para identificar las dimensiones, y lo más importante: **normalizar**.
Esto proporcionará ventajas como:

- Mejora del rendimiento en operaciones JOIN
- Reducción del tamaño de índices
- Independencia frente a cambios en los datos originales
- Simplificación del modelo analítico

Respecto a las tablas de hechos, al crearlas ya se han definido las claves primarias, *Primary Keys - PK*, y claves foráneas, *Foreign Keys - FK*, cuya importancia radica en que las PK identifica de forma única cada fila en una tabla, mientras que las FK permite establecer relaciones con las PK de otras tablas.

- De la tabla fact_anuncios: Se utilizan las claves foráneas para relacionar esta tabla de hechos con las tablas de dimensiones, creadas anteriormente.

FOREIGN KEY (id_host) REFERENCES dim_host(id_host),
FOREIGN KEY (id_barrio) REFERENCES dim_barrio(id_barrio),
FOREIGN KEY (id_tipo_alojamiento) REFERENCES dim_tipo_alojamiento(id_tipo_alojamiento),
FOREIGN KEY (id_tipo_licencia) REFERENCES dim_tipo_licencia(id_tipo_licencia)

- De la tabla fact_disponibilidad: Se utilizan las claves primaria y foránea para relacionar las tablas de hechos entre ellas.

PRIMARY KEY (id_anuncio, fecha),
FOREIGN KEY (id_anuncio) REFERENCES fact_anuncios(id_anuncio)

7.5. Data Manipulation Language

El paso a paso seguido para la carga, manipulación y transformación de nuestros datos, se detalla a continuación, mencionando las líneas del script de SQL. Todos los scripts fueron ejecutados desde MySQL Workbench. Al igual que comentado en el paso anterior, por su

parte, el script de SQL también cuenta con comentarios explicativos de todos los pasos que se ejecutan.

1. Habilitar la carga de datos locales → Líneas 170-171
2. Carga de datos en las tablas *staging*: LOAD DATA LOCAL INFILE, y sus respectivas validaciones: SELECT FROM
    a. staging_listings:
        i. Carga → líneas 175-193
        ii. Validación → líneas 197-201
    b. staging_calendar:
        i. Carga → líneas 206-222
        ii. Validación → líneas 226-230
    c. staging_neighbourhoods:
        i. Carga → lineas 236-248
        ii. Validación → líneas 252-256
3. Poblar las tablas de dimensiones: INSERT INTO, y sus respectivas validaciones: SELECT:
    a. dim_barrio:
        i. Poblar → líneas 266-273
        ii. Validación → líneas 277 y 278
    b. dim_host:
        i. Poblar → líneas 285-298
        ii. Validación → líneas 302 y 303
    c. dim_tipo_alojamiento:
        i. Poblar → líneas 310-313
        ii. Normalizamos datos, creando una columna de “categoría”: UPDATE y SET → líneas 317-326 *(*)*
    d. dim_tipo_licencia:
        i. Poblar → líneas 333-336
4. Poblar la tabla de hechos fact_anuncios: INSERT INTO → líneas 343-380
5. Cálculo del centroide del barrio y actualización del dato en dim_barrio → líneas 387-403 [3]
6. Poblar la tabla de hechos fact_disponibilidad: LOAD DATA LOCAL INFILE → líneas 410-426 [4]
7. Validaciones de cargas de las tablas de hechos → líneas 432, 433, 436 y 437

Como se puede observar, en la tabla de hechos fact_anuncios, se ha utilizado el comando LEFT JOIN hacia las dimensiones correspondientes, reemplazando de esta manera, los atributos textuales por claves sustitutas, normalizando y optimizando el modelo para consultas analíticas.

[3] Se ha utilizado el comando SET SQL_SAFE_UPDATES para ejecutar actualizaciones sin condiciones estrictas.
[4] Se ha utilizado LOAD DATA LOCAL INFILE en lugar de INSERT INTO por la cantidad de datos y lo pesada que resultó esta tabla, arrojando múltiples errores en su carga de datos.

Con el objetivo de facilitar el análisis espacial se calculó el centroide de cada barrio mediante el promedio de las coordenadas de los anuncios pertenecientes a dicho barrio.
Para ello, se utilizaron las funciones: AVG(latitud) y AVG(longitud), y los resultados se almacenan como atributos en dim_barrio. Esto, más adelante en el proyecto, permitirá representar cada barrio mediante un punto central en análisis geoespaciales.

7.6. Validación de integridad de datos

Como se ha podido comprobar, después de cada proceso de carga se ejecutaron consultas de validación para asegurar la consistencia de la información.

Las validaciones realizadas incluyen: COUNT(*) para verificar el total de filas cargadas en cada tabla; COUNT(id_anuncio) para comprobar que no existen valores nulos en la clave primaria; y COUNT(DISTINCT id_anuncio) para detectar posibles duplicados.

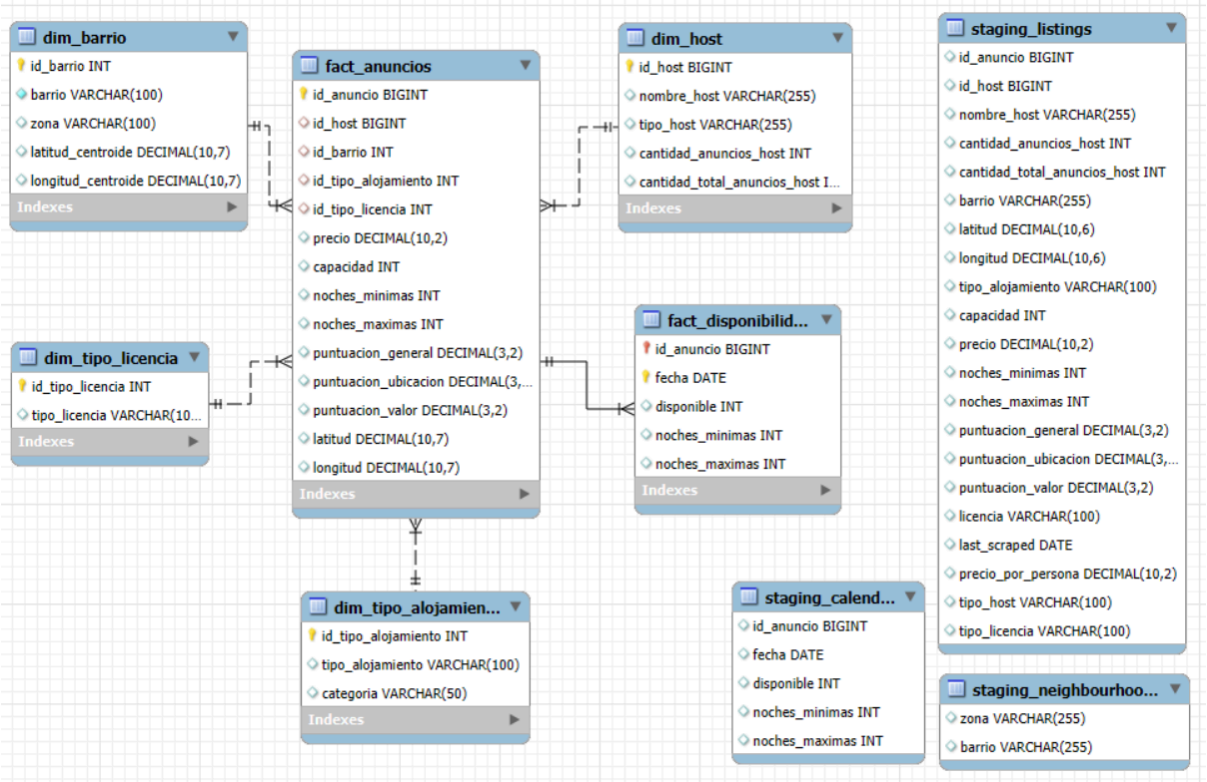
Resultados principales:

- 16.676 anuncios cargados correctamente
- 6.086.742 registros de disponibilidad
- 73 barrios distribuidos en 10 zonas

Estas verificaciones aseguran que la carga se realizó sin pérdida de datos.

7.7. Diagrama de Entidad-Relación, ERD

A continuación se muestra el diagrama Entidad-Relación de nuestro modelo:



Este modelo permite organizar la información en entidades independientes, evitando redundancias y facilitando las relaciones entre anuncios, anfitriones, barrios y disponibilidad.

Las flechas en este diagrama representan restricciones físicas, utilizando las claves foráneas que se han definido en el modelo. Si no hay flecha entre las tablas, significa que no existe una clave foránea definida entre dichas tablas.
Se observa en el diagrama las tablas que se han creado y poblado, procesos descritos en los puntos 7.4 y 7.5., y se puede observar cómo se relacionan entre ellas:

Tabla de hechos **fact_anuncios** → Representa cada propiedad publicada en Airbnb.

- Su clave primaria es id_anuncio (PK), que se relaciona con id_anuncio de la tabla de hechos fact_disponibilidad:

Cada anuncio puede tener múltiples registros de disponibilidad, uno por cada fecha del calendario.

- Sus claves foráneas son:
    - id_host, que se relaciona con la clave primaria id_host de la tabla dim_host:

Un host puede gestionar múltiples anuncios, pero cada anuncio pertenece a un único host.

    - id_barrio, que se relaciona con la clave primaria id_barrio de la tabla dim_barrio:

Un barrio puede contener múltiples anuncios, mientras que cada anuncio está ubicado en un único barrio.

    - id_tipo_alojamiento, que se relaciona con la clave primaria id_tipo_alojamiento de la tabla dim_tipo_alojamiento:

Un tipo de alojamiento puede describir a múltiples anuncios, mientras que cada anuncio solo puede ser de un tipo.

    - id_tipo_licencia, que se relaciona con la clave primaria id_tipo_licencia de la tabla dim_tipo_licencia:

Un tipo de licencia puede categorizar a múltiples anuncios, mientras que cada anuncio solo puede tener un tipo de licencia.

Tabla de hechos **fact_disponibilidad** → Registra la disponibilidad diaria de cada anuncio.
Tiene una clave primaria compuesta:

- id_anuncio
- fecha

Por otro lado, se observa que las tablas staging no tienen flechas, puesto que no forman parte del modelo analítico, no tienen integridad referencial, y solo reciben datos crudos del CSV. Aquí corroboramos que estas tablas son parte del proceso ETL, pero no del modelo dimensional.

En resumen, el diseño del modelo prioriza la separación entre entidades descriptivas (dimensiones) y entidades que contienen métricas (hechos).

Esta estructura reduce redundancia de información y facilita el análisis multidimensional del mercado, permitiendo estudiar la oferta según ubicación, tipo de alojamiento, tipo de licencia y disponibilidad temporal.

7.8. DUMP del script

Por último, se ha generado el archivo DUMP desde MySQL Workbench, siguiendo los pasos:

1. Abrir MySQL Workbench
2. Clic en Server → Data Export
3. Seleccionamos la base de datos: airbnb_barcelona_2025
4. Tipo de exportación seleccionada → Export to Self-Contained File
5. En export options, seleccionamos “Dump Structure and Data”
6. Elegimos ubicación local para la exportación
7. Pulsamos en “Start export

8. Análisis y visualización en PowerBI

8.1. Introducción

Una vez construido el modelo de datos en SQL y estructurada la información mediante un modelo dimensional, se ha procedido con la fase de visualización y análisis exploratorio utilizando Power BI. Esta herramienta fue seleccionada por su capacidad para conectarse de forma eficiente a bases de datos relacionales, así como por su potencial para transformar grandes volúmenes de datos en visualizaciones interactivas orientadas a la toma de decisiones.

En este proyecto, Power BI se ha utilizado para construir un dashboard analítico estructurado en varias páginas temáticas, diseñado para sintetizar los principales indicadores del mercado y facilitar la interpretación de los datos por parte de stakeholders del sector inmobiliario.

8.2. Conexión SQL - PowerBI

El modelo entidad-relación diseñado constituye la base estructural del sistema de análisis desarrollado. Esta arquitectura permite organizar la información del mercado de Airbnb en Barcelona de forma eficiente, facilitando consultas analíticas, agregaciones multidimensionales y visualizaciones dinámicas.

Gracias a este diseño, el modelo de datos se ha podido integrar de forma óptima con Power BI, permitiendo analizar la oferta del mercado según distintas perspectivas, y proporcionando una base sólida para la generación de insights estratégicos para stakeholders del sector inmobiliario.

Para cargar los datos desde SQL a PowerBI, se han seguido los siguientes pasos:

1. Clic en Obtener Datos
2. Buscar MySQL
3. Instalar el Connector/NET 8.0.29 (Power BI requiere este conector para comunicarse con bases de datos MySQL)
4. Reiniciar PowerBi
5. Clicar en Obtener Datos → My SQL
6. Introducir el servidor: localhost, y el nombre de la base de datos: airbnb_barcelona_2025
7. En la ventana emergente, clicar en la pestaña de base de datos, e introducir nuestro nombre de usuario y contraseña de SQL, y clicar en conectar
8. Aparecerán todas las tablas de nuestra base de datos de SQL; se han seleccionado todas las tablas de dimensiones y de hechos
9. Pulsar en cargar

8.3. Modelo de datos

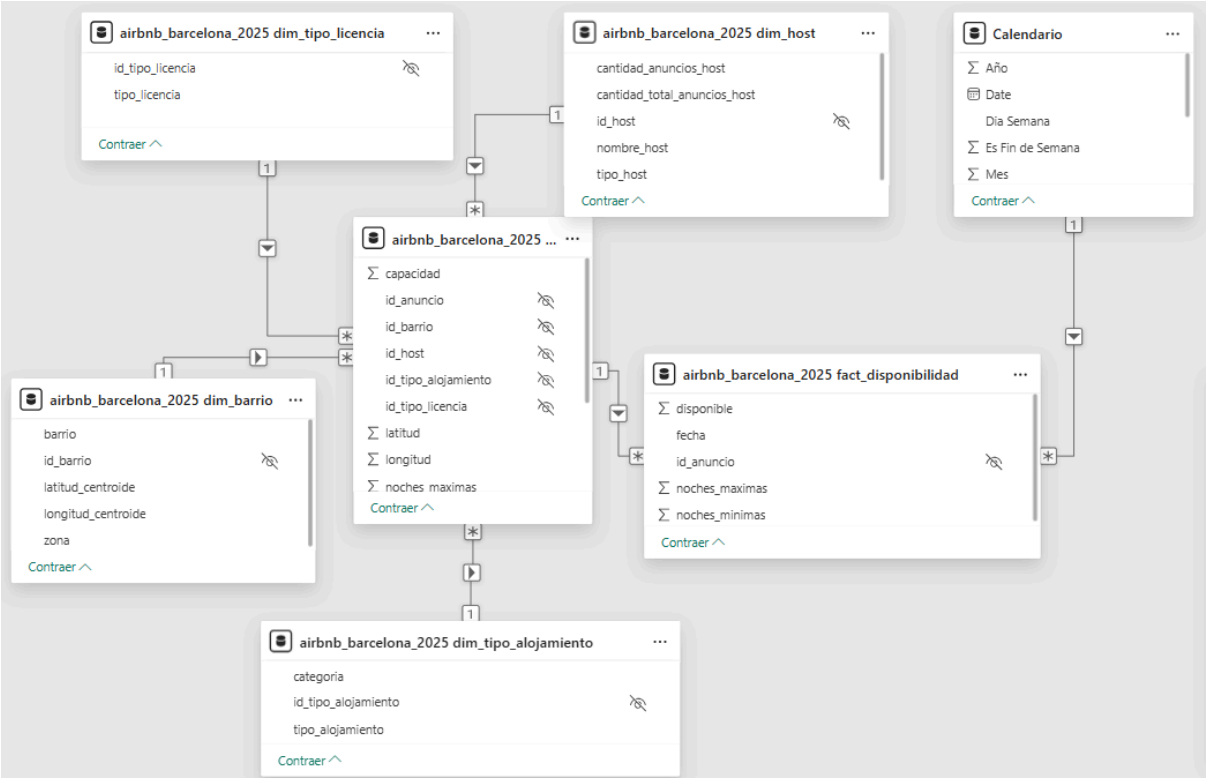
Al conectar Power BI con la base de datos desarrollada en SQL, el modelo de datos se carga automáticamente en la vista de relaciones. En esta etapa es posible visualizar la estructura del modelo dimensional implementado previamente, donde las tablas de dimensión se conectan con las tablas de hechos.

La visualización del modelo en Power BI también permite corroborar la correcta carga e integración de las tablas procedentes de SQL, verificando que las relaciones entre dimensiones y tablas de hechos se establecen correctamente.

Las tablas de dimensión se conectan con las tablas de hechos mediante relaciones uno a muchos (1:N), donde las dimensiones contienen valores únicos y las tablas de hechos registran múltiples observaciones asociadas.

Adicionalmente, en Power BI se creó una tabla calendario que permite estructurar el análisis temporal de los datos. Esta tabla contiene atributos derivados de la fecha, como año, mes o día, y se relaciona con la tabla fact_disponibilidad mediante el campo de fecha.

La incorporación de esta tabla facilita el análisis temporal del mercado, permitiendo estudiar la disponibilidad de los alojamientos a lo largo del tiempo y habilitando funcionalidades de inteligencia temporal dentro del modelo.



8.4. PowerQuery

Se ha utilizado también Power Query para reemplazar algunos valores de las tablas que estaban escritos en inglés, traduciéndose al castellano, con el objetivo de que en las visualizaciones se tuviera todo escrito en un mismo idioma.

Las tablas que sufrieron algún reemplazo, se mencionan a continuación:

- dim_host
- dim_tipo_alojamiento
- dim_tipo_licencia

Entre los valores traducidos se encuentran los tipos de alojamiento (por ejemplo, "Entire home/apt", "Private room", "Shared room").

8.5. Medidas DAX

Para proceder a construir las visualizaciones, se han creado las siguientes medidas DAX:

Tabla Calendario (DAX)

La dimensión de tiempo no se ha importado desde MySQL sino que se ha creado directamente en Power BI mediante DAX (Modeling > New Table). El rango de fechas se

calcula dinámicamente a partir del mínimo y máximo de la columna fecha de fact_disponibilidad, cubriendo el período 14/09/2025 – 14/09/2026.

DAX — Tabla Calendario

```
Calendario =

ADDCOLUMNS(
CALENDAR(
MIN('fact_disponibilidad'[fecha]),
MAX('fact_disponibilidad'[fecha])
),
 "Año", YEAR([Date]),
 "Mes", MONTH([Date]),
"Nombre Mes", FORMAT([Date], "MMMM"),
"Mes Año", FORMAT([Date], "MMM YYYY"),
"Orden Mes Año",
YEAR([Date]) * 100 + MONTH([Date]),
"Trimestre", "T" & FORMAT([Date], "Q"),
"Semana", WEEKNUM([Date], 2),
"Dia Semana", FORMAT([Date], "dddd"),
"Es Fin de Semana", IF(WEEKDAY([Date], 2) > 5, 1, 0)
 )
```

Nota técnica importante: dentro de ADDCOLUMNS no se puede referenciar Calendario[Date] porque la tabla aún no existe en ese momento. Se debe usar [Date] directamente. Además, para que la columna 'Mes Año' se ordene cronológicamente (y no alfabéticamente), se aplica la función 'Ordenar por columna': Mes Año --> Orden Mes Año, desde la vista Datos > Herramientas de columna > Ordenar por columna.

Medidas DAX

Todas las medidas se han creado en una tabla vacía dedicada (tabla 'Medidas'), siguiendo la práctica de centralizar las métricas para facilitar el mantenimiento del modelo. Cada expresión DAX es una medida independiente creada mediante Modeling > New Measure.

Para crear la tabla de medidas: Modeling > New Table > escribir Medidas = {1} y ocultar la columna generada. Luego, desde esa tabla, crear cada medida con New Measure.

Medidas generales de mercado

```
Total Anuncios = COUNTROWS(fact_anuncios)
Total Hosts = DISTINCTCOUNT(dim_host[id_host])
Precio Promedio = AVERAGE(fact_anuncios[precio])
```

Medidas de concentración de hosts

```
Hosts Multilisting =
CALCULATE(
DISTINCTCOUNT(dim_host[id_host]),
dim_host[tipo_host] = "Multiple"
)

% Multilisting =
DIVIDE(
CALCULATE(
 COUNTROWS(fact_anuncios),
dim_host[tipo_host] = "Multiple"
),
[Total Anuncios]
)
```

El campo tipo_host en dim_host clasifica a cada anfitrión como 'Individual' (1 solo anuncio) o 'Professional' (2 o mas anuncios). El porcentaje de multilisting se ha calculado sobre Total Anuncios (no sobre Total Hosts) para expresar qué fracción de la oferta está en manos de operadores profesionales.

Medidas regulatorias (licencias)

```
% Sin Licencia =
DIVIDE(
CALCULATE(
[Total Anuncios],
dim_tipo_licencia[tipo_licencia] = "Sin licencia"
),
[Total Anuncios]
)
```

% sobre Total Mercado (dinamico por licencia)

```
% sobre Total Mercado =
DIVIDE(
[Total Anuncios],
CALCULATE(
[Total Anuncios],
ALL(dim_tipo_licencia)
)
)
```

Con la medida '% sobre Total Mercado' se ha usado ALL(dim_tipo_licencia) para eliminar el filtro del segmentador de licencia del denominador. Esto ha permitido que, al seleccionar

una licencia especifica, el KPI muestre su peso real sobre el total del mercado, en lugar de mostrar siempre 100%.

% Hosts Profesionales (en contexto de licencia)

```
% Hosts Profesionales =
DIVIDE(
CALCULATE(
DISTINCTCOUNT(fact_anuncios[host_id]),
dim_host[tipo_host] = "Professional"
),
DISTINCTCOUNT(fact_anuncios[host_id])
)
```

Medidas de disponibilidad

```
Dias Disponibles =
CALCULATE(
COUNTROWS(fact_disponibilidad),
fact_disponibilidad[disponible] = TRUE()
)

Total Dias = COUNTROWS(fact_disponibilidad)

% Disponibilidad =
DIVIDE(
[Dias Disponibles],
[Total Dias]
)

Promedio Dias Disponibles por Anuncio =
DIVIDE(
[Dias Disponibles],
DISTINCTCOUNT(fact_disponibilidad[listing_id])
)
```

% Disponibilidad Mensual (con tabla Calendario)

```
% Disponibilidad Mensual =
DIVIDE(
CALCULATE(
COUNTROWS(fact_disponibilidad),
fact_disponibilidad[disponible] = TRUE()
),
COUNTROWS(fact_disponibilidad)
)
```

Nota metodológica: con la disponibilidad se quiere reflejar únicamente el estado del calendario publicado por los anfitriones al momento del scraping (14-15 sep 2025). No representa reservas efectivas ni ocupación real.

Medidas de distribución geográfica

```
% Oferta Barrio =
DIVIDE(
COUNTROWS(fact_anuncios),
CALCULATE(COUNTROWS(fact_anuncios), ALL(dim_barrio))
)

Precio Promedio Barrio =
AVERAGE(fact_anuncios[precio])

-- Usar con dim_barrio[barrio] o dim_barrio[zona] en el eje.
```

8.6. Estructura del dashboard

A continuación se quiere detallar la configuración exacta de cada página: tipo de visual, campos asignados en cada eje y medidas utilizadas.

Página 1 | ¿Dónde está concentrada la oferta? | Dimensión: What + Where

KPIs (Tarjetas)

16.676	4.730	91,24 %	186,86 EUR	54,12 %
Total Anuncios	Total Hosts	% Multilisting	Precio Promedio	% con Licencia

Grafico 1 — Anuncios por tipo de alojamiento

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de anillos (Donut)`	Muestra composicion porcentual
Leyenda	`dim_tipo_alojamiento[tipo_alojamiento]`	Categorias: completo, privada, compartida, hotel
Valores	`[Total Anuncios]`	Medida COUNTROWS(fact_anuncios)

Grafico 2 — Anuncios por zona / distrito

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de barras agrupadas`	Barras horizontales, no apiladas
Eje Y	`dim_barrio[zona]`	Distrito como categoria
Valores (Eje X)	`[Total Anuncios]`	Ordenar descendente por Total Anuncios

Grafico 3 — Mapa de burbujas por barrio

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Mapa (visual estandar con burbujas)`	No mapa relleno ni Azure Maps
Ubicacion	`dim_barrio[barrio]`	Nombre del barrio
Latitud	`dim_barrio[latitud]`	Tipo datos: Latitud
Longitud	`dim_barrio[longitud]`	Tipo datos: Longitud
Tamanio	`[Total Anuncios]`	Mayor burbuja = mayor concentracion
Informacion	`barrio, zona, [Total Anuncios], [Precio Promedio]`	Tooltip interactivo

Página 2 | ¿Quién controla el mercado? | Dimensión: Who + How

Segmentador

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Segmentacion de datos (Slicer)`	Estilo: botones / horizontal
Campo	`dim_host[tipo_host]`	Valores: Individual / Professional

KPIs (Tarjetas) — dinamicas segun segmentador

Campo visual	Valor / Dimensión	Notas
KPI 1	`[Total Anuncios]`	Se filtra por tipo_host seleccionado
KPI 2	`[Total Hosts]`	DISTINCTCOUNT(dim_host[id_host])
KPI 3	`[Precio Promedio]`	AVERAGE(fact_anuncios[precio])

Grafico 1 — Anuncios por tipo de alojamiento

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de columnas agrupadas`	Barras verticales
Eje X	`dim_tipo_alojamiento[tipo_alojamiento]`	Sin leyenda adicional
Valores	`[Total Anuncios]`	Cambia segun slicer tipo_host

Grafico 2 — Anuncios por zona

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de barras agrupadas`	Horizontal, ordenado desc.
Eje Y	`dim_barrio[zona]`	Distrito como categoria
Valores	`[Total Anuncios]`	Cambia segun slicer tipo_host

Página 3 | Licencias y estructura regulatoria | Dimensión: Why

Segmentador

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Segmentacion de datos (Slicer)`	Seleccion unica o multiple
Campo	`dim_tipo_licencia[tipo_licencia]`	Valores: Con licencia / Sin licencia / Exento

KPIs (Tarjetas)

Campo visual	Valor / Dimensión	Notas
KPI 1	`[Total Anuncios]`	Volumen bajo licencia seleccionada
KPI 2	`[% sobre Total Mercado]`	Peso relativo — usa ALL(dim_tipo_licencia)
KPI 3	`[Precio Promedio]`	Precio medio en licencia seleccionada
KPI 4	`[% Hosts Profesionales]`	Profesionalizacion dentro de la licencia

Grafico 1 — Anuncios por licencia y tipo de host

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de columnas apiladas`	Apilado (no agrupado)
Eje X	`dim_tipo_licencia[tipo_licencia]`	Con licencia / Sin licencia / Exento
Valores	`[Total Anuncios]`	Total por licencia
Leyenda	`dim_host[tipo_host]`	Individual vs Professional (colores)

Grafico 2 — Precio promedio por tipo de licencia

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de columnas agrupadas`	Un solo color, sin leyenda
Eje X	`dim_tipo_licencia[tipo_licencia]`	Comparacion entre las 3 categorias
Valores	`[Precio Promedio]`	Revela prima de precio por regularizacion

Grafico 3 — Anuncios por zona (filtrable por licencia)

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de barras horizontales`	Ordenado descendente
Eje Y	`dim_barrio[zona]`	Cambia segun slicer de licencia
Valores	`[Total Anuncios]`	Distribucion territorial por licencia

Página 4 | Estacionalidad: intensidad temporal | Dimension: When

Segmentadores

Campo visual	Valor / Dimensión	Notas
Slicer 1	`dim_host[tipo_host]`	Individual / Professional
Slicer 2	`dim_barrio[zona]`	Filtro territorial opcional

KPIs (Tarjetas)

Campo visual	Valor / Dimensión	Notas
KPI 1	`[% Disponibilidad]`	62,22 % promedio global
KPI 2	`[Promedio Dias Disponibles por Anuncio]`	227 dias en el periodo analizado

Grafico 1 — Evolucion temporal de disponibilidad por tipo de alojamiento

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Grafico de lineas (area)`	Linea por tipo de alojamiento
Eje X	`Calendario[Mes Año]`	Ordenado por Orden Mes Año (DAX)
Valores	`[% Disponibilidad]`	o [% Disponibilidad Mensual]
Leyenda	`dim_tipo_alojamiento[tipo_alojamiento]`	Reemplaza gráfico unico sin leyenda

Grafico 2 — Heatmap de disponibilidad (Matriz con formato condicional)

Campo visual	Valor / Dimensión	Notas
Tipo de visual	`Matriz`	Equivalente a heatmap en Power BI
Filas	`Calendario[Mes Año]`	Sep 2025 ... Ago 2026 (cronologico)
Columnas	`dim_barrio[zona]`	Un distrito por columna
Valores	`[% Disponibilidad]`	Formato: porcentaje sin decimales
Color	`Formato condicional > Color de fondo`	Escala: rojo (bajo) → verde (alto)

8.7. KPIs y valores registrados (scraping 14 sep 2025)

Con los siguientes indicadores se puede representar el estado del mercado en la fecha de captura de datos. Son los valores de referencia que aparecen en las tarjetas del dashboard sin ningún filtro activo.

KPI	Medida DAX	Página
Total Anuncios	COUNTROWS(fact_anuncios)	1, 2, 3
Total Hosts	DISTINCTCOUNT(fact_anuncios[id_host])	1, 2
% Anuncios Multilisting	DIVIDE(anuncios multi, Total Anuncios)	1
Precio Promedio	AVERAGE(fact_anuncios[precio])	1, 2, 3

% Anuncios con Licencia	DIVIDE(anuncios licencia, Total Anuncios)	1
% Hosts Profesionales	DIVIDE(hosts prof, DISTINCTCOUNT hosts)	3
% Disponibilidad Global	DIVIDE(dias disponibles, total dias)	4
Días Disponibles Prom.	DIVIDE(dias disp, DISTINCTCOUNT listing_id)	4

8.8. Insights relevantes

A partir del análisis visual desarrollado en el dashboard de Power BI, estructurado en cuatro páginas temáticas, se identificaron los siguientes insights relevantes, orientados a dar respuesta a las preguntas analíticas operativas planteadas en el inciso 3.2:

1. Mercado altamente profesionalizado

El 91,2% de los anuncios pertenecen a hosts con múltiples propiedades, con una media de 4,65 propiedades frente a 1 de los individuales. No es un mercado de particulares, es un mercado de **operadores profesionales.**

2. Concentración geográfica extrema

El 60% de la oferta se concentra en Eixample y Ciutat Vella, intensificando la presión sobre el mercado residencial. Los distritos periféricos quedan muy por debajo en volumen.

3. Formalización parcial con riesgo regulatorio:

Sólo el 54% declara licencia HUT. El 46% restante opera en **zona de riesgo legal**, aunque su reducción gradual refuerza el valor de los activos legales.

4. Modelo dominante: alojamiento completo

El 99% de la oferta se concentra en vivienda completa y habitación privada, desplazando vivienda residencial hacia uso turístico exclusivo.

5. Precio premium en zonas de escasez:

Los anuncios con licencia tienen un precio promedio de 261€, un 22% superior a los particulares. Sants-Montjuïc, con solo 868 anuncios, alcanza el precio promedio más alto: **301,46€**, demostrando que **menor oferta genera mayor rentabilidad.**

6. Estacionalidad clara del mercado: la disponibilidad

Es estable en otoño-invierno y se reduce en primavera-verano por mayor presión turística. Los hosts profesionales mantienen mayor disponibilidad media (62,5%) frente a los individuales (58,7%).

9. Conclusiones

9.1. Oportunidades y riesgos

A partir de los insights identificados, se presentan las siguientes oportunidades, riesgos y recomendaciones de negocio para MUI, considerando el contexto regulatorio vigente en materia de viviendas turísticas en Barcelona para el año 2025:

Oportunidades

- Zonas de baja densidad y alto precio como Sants-Montjuïc → **mayor rentabilidad por activo y menor competencia**
- Activos con licencia HUT → **seguridad jurídica hasta 2028** y valor creciente a largo plazo
- **Temporada baja** → posibilidad de alquileres más largos para mantener ingresos.

Riesgos

- 46% sin licencia → **exposición a inspecciones, sanciones y cierre**
- Alta concentración en Eixample y Ciutat Vella → **mayor probabilidad de nuevas restricciones regulatorias**
- **Estacionalidad** → alta demanda en primavera-verano, baja ocupación en invierno.

9.2. Recomendaciones estratégicas a futuro para MUI

1. Priorizar activos con licencia HUT en zonas de escasez

Invertir en zonas como Sants-Montjuïc donde la escasez de oferta legal genera rentabilidad superior y menor riesgo regulatorio.

2. Evitar sobreexposición en zonas saturadas

Eixample y Ciutat Vella concentran mayor presión regulatoria y riesgo de nuevas restricciones de densidad turística.

3. Anticiparse a la formalización del mercado

Adquirir activos legales antes de que la reducción del mercado ilegal eleve aún más el valor de las licencias HUT.

4. Diversificar hacia media estancia en temporada baja

Complementar el alquiler turístico con modelos de 31-180 días para estabilizar ingresos y reducir la volatilidad estacional.

9.3. Sugerencias para análisis futuros

El presente análisis constituye una fotografía del mercado en un momento específico (septiembre de 2025) y sienta las bases para un seguimiento continuo del mercado de viviendas turísticas en Barcelona:

Análisis periódico y comparativo entre períodos

Para enriquecer el análisis, se recomienda replicar el análisis con datasets de ediciones anteriores y futuras de Inside Airbnb, lo que permitiría identificar tendencias en precios, saturación territorial y composición de la oferta a lo largo del tiempo. La comparación entre años contribuye en mayor medida a medir el impacto real de los cambios regulatorios sobre el volumen de anuncios, los niveles de precios y el cumplimiento normativo, aportando una dimensión temporal que el análisis transversal actual no contempla.

Seguimiento del impacto regulatorio

La revisión del PEUAT representa un hito de alto impacto sobre el mercado. Se recomienda monitorear su efecto sobre la reducción del stock de licencias HUT y la evolución de precios ante una oferta legal progresivamente más restringida, permitiendo a MUI anticiparse a cambios normativos y ajustar su estrategia de inversión.

Exploración de zonas emergentes fuera del centro

Se recomienda profundizar en el estudio de distritos periféricos con menor densidad turística, como Nou Barris, Sant Andreu u Horta-Guinardó, para identificar oportunidades con menor presión regulatoria, menor competencia y potencial de revalorización ante una eventual redistribución de la demanda.

Supervisión del mercado sin licencia

Analizar la evolución del segmento sin licencia en ediciones futuras permitiría comprender cómo avanza la formalización del mercado y en qué medida su reducción impacta en los precios de los activos legales.

Incorporación de variables pendientes y nuevas fuentes

El análisis de las variables noches_minimas y noches_maximas del dataset calendar ha quedado fuera del alcance del presente proyecto, al igual que las variables relacionadas con las reviews presentes en el dataset de anuncios (listings). No obstante, su incorporación en futuros análisis podría enriquecer la comprensión tanto de las características de los anuncios como de las estrategias de gestión del calendario adoptadas por los anfitriones.

Por su parte, en el archivo listings disp.ipynb se ha creado un subconjunto del dataset considerando únicamente los anuncios que declaran precio, eliminando aquellos registros con valores nulos en esta variable. Esta preparación de los datos permite, potencialmente, analizar con mayor profundidad el comportamiento de los anuncios con precio declarado. No obstante, este subconjunto no se incorpora en el análisis desarrollado en el presente informe, quedando como una base preparada para posibles exploraciones posteriores. En futuras investigaciones podría resultar enriquecedor comparar este subconjunto con el de anuncios que no declaran precio, con el fin de identificar posibles diferencias en las características de los anuncios, el perfil de los propietarios o su distribución por barrios.

Del mismo modo, cruzar los datos con otras plataformas como Booking.com e integrar estadísticas de turismo del Ayuntamiento de Barcelona o explorar la relación entre la oferta turística y la ocupación hotelera de la ciudad son análisis que no se ha llegado a realizar pero que representan un salto cualitativo importante. Un gran desafío para próximas iteraciones del proyecto.

10. Anexo

10.1. Diccionario de datos

El presente diccionario documenta las variables seleccionadas de los datasets originales de Inside Airbnb para Barcelona, utilizadas en el análisis desarrollado en el marco de las preguntas de negocio definidas en el inciso 3.2.

Dataset: listings

Columnas documentadas: 21 | Fuente: Inside Airbnb — Ciudad de Barcelona

Campo	Tipo de Dato	Descripción
id_anuncio	int64	Identificador único del anuncio (listing) en la plataforma Airbnb. Es la clave primaria de la tabla; cada fila corresponde a un alojamiento diferente.

Campo	Tipo de Dato	Descripción
id_host	int64	Identificador único del anfitrión propietario del anuncio. Permite vincular varios anuncios a un mismo anfitrión, ya que una persona puede gestionar múltiples alojamientos.
nombre_host	object	Nombre público del anfitrión tal como aparece en su perfil de Airbnb. Puede ser un nombre parcial o un alias. Contiene 3 valores nulos en el dataset.
cantidad_anuncios_host	int32	Número de anuncios activos que el anfitrión tenía publicados en la plataforma al momento del scraping. Refleja la actividad actual del host.
cantidad_total_anuncios_host	int32	Número total de anuncios publicados por el anfitrión a lo largo de su historial en Airbnb, incluyendo aquellos que ya no están activos. Puede ser mayor que cantidad_anuncios_host.
barrio	object	Nombre del barrio donde se ubica el alojamiento, normalizado mediante geocodificación inversa a partir de las coordenadas geográficas. Corresponde a la división administrativa oficial de Barcelona.
latitud	float64	Coordenada geográfica de latitud del alojamiento expresada en grados decimales (sistema WGS84). Airbnb aplica una ligera obfuscación (~150 m) para proteger la privacidad del anfitrión.
longitud	float64	Coordenada geográfica de longitud del alojamiento expresada en grados decimales (sistema WGS84). Se utiliza junto con latitud para geolocalizar el alojamiento en mapas.
tipo_alojamiento	object	Categoría del alojamiento definida por Airbnb según el nivel de acceso que tendrá el huésped. Valores posibles: 'Entire home/apt' (alojamiento completo), 'Private room' (habitación privada), 'Shared room' (habitación compartida) y 'Hotel room' (habitación de hotel).
capacidad	int64	Número máximo de huéspedes que el alojamiento puede alojar de forma simultánea según la configuración establecida por el anfitrión. Influye directamente en la fijación del precio.
precio	float64	Precio por noche del alojamiento en euros (€) al momento del scraping, ya procesado como valor numérico. Contiene 1.521 valores nulos (~9%) correspondientes a anuncios sin precio publicado.
noches_minimas	int64	Número mínimo de noches que el anfitrión exige para aceptar una reserva. Valores elevados pueden indicar que el alojamiento está orientado a estancias de media o larga duración.
noches_maximas	int64	Número máximo de noches permitido por el anfitrión para una única reserva continua. Valores muy altos (ej. 1125) indican que no existe restricción práctica de estancia máxima.
puntuacion_general	float64	Puntuación global del alojamiento calculada como promedio de todas las reseñas de huéspedes. Se expresa en una escala

Campo	Tipo de Dato	Descripción
		de 0 a 5. Contiene 3.944 nulos correspondientes a alojamientos sin reseñas.
puntuacion_ubicacion	float64	Puntuación específica de la ubicación del alojamiento según las valoraciones de los huéspedes. Refleja la percepción sobre accesibilidad, transporte y entorno. Escala de 0 a 5. Mismo patrón de nulos que puntuacion_general.
puntuacion_valor	float64	Puntuación de la relación calidad-precio del alojamiento según los huéspedes. Escala de 0 a 5. Suele correlacionar con el precio absoluto y la puntuación general. Mismo patrón de nulos que puntuacion_general.
licencia	object	Número de licencia o registro turístico oficial del alojamiento según la normativa del Ayuntamiento de Barcelona (HUTB - Habilitación de Uso Turístico de Barcelona). Contiene 3.995 nulos (~24%), lo que puede indicar alojamientos sin licencia registrada o no declarada.
last_scraped	datetime64[ns]	Fecha y hora en que Inside Airbnb realizó la extracción automática (scraping) de los datos de este anuncio desde la plataforma. Permite identificar la vigencia y actualidad de cada registro.
precio_por_persona	float64	Precio por noche dividido entre la capacidad máxima del alojamiento (precio / capacidad). Variable derivada que permite comparar el coste real entre alojamientos de distinto tamaño. Hereda los 1.521 nulos del campo precio.
tipo_host	object	Clasificación del anfitrión según la cantidad de anuncios que gestiona. Variable derivada que distingue entre anfitriones particulares (con uno o pocos anuncios) y anfitriones profesionales o gestores de múltiples propiedades.
tipo_licencia	object	Categorización del estado o tipo de licencia turística del alojamiento. Variable derivada a partir del campo licencia que agrupa los registros según si disponen de licencia válida, están exentos, o carecen de ella.

Dataset: calendar

Columnas documentadas: 5 | Fuente: Inside Airbnb — Ciudad de Barcelona

Campo	Tipo de Dato	Descripción
id_anuncio	int64	Identificador único del anuncio al que pertenece el registro de disponibilidad. Clave foránea que permite relacionar cada fila del calendario con su alojamiento correspondiente en el dataset listings.
fecha	object	Fecha específica del calendario del alojamiento en formato texto (YYYY-MM-DD). Cada combinación de id_anuncio +

Campo	Tipo de Dato	Descripción
		fecha es única y representa un día concreto en el calendario de disponibilidad del anuncio.
disponible	object	Indicador de disponibilidad del alojamiento para la fecha correspondiente. Valores posibles: 't' (true = disponible para reservar) o 'f' (false = no disponible, ya sea por reserva existente o bloqueo del anfitrión).
noches_minimas	int64	Número mínimo de noches requerido para realizar una reserva en esa fecha específica. Puede variar día a día dentro del mismo anuncio, ya que el anfitrión puede configurar reglas distintas según la temporada.
noches_maximas	int64	Número máximo de noches permitido para una reserva que incluya esa fecha específica. Al igual que noches_minimas, puede ser diferente para cada fecha del calendario según la configuración del anfitrión.

Dataset: neighbourhoods

Columnas documentadas: 2 | Fuente: Inside Airbnb — Ciudad de Barcelona

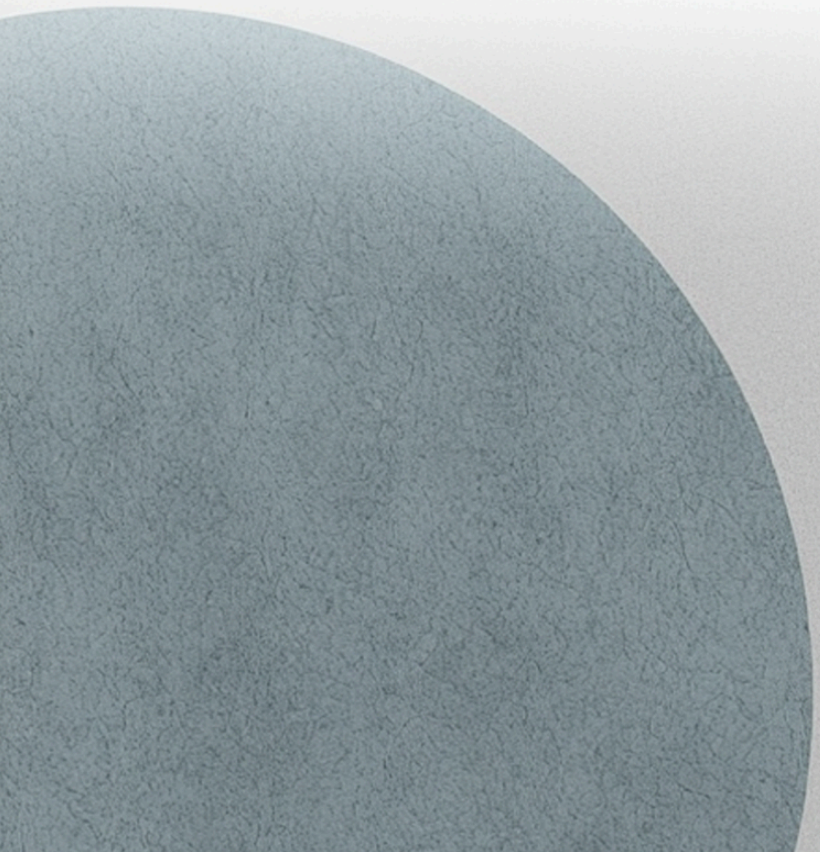
Campo	Tipo de Dato	Descripción
zona	object	Nombre del distrito o zona administrativa de Barcelona al que pertenece el barrio. Barcelona se divide en 10 distritos oficiales (ej. Eixample, Gràcia, Sant Martí). Permite agrupar los barrios en unidades territoriales más amplias para análisis a nivel de distrito.
barrio	object	Nombre oficial del barrio dentro del distrito correspondiente. Barcelona cuenta con 73 barrios reconocidos oficialmente. Este campo es la clave de unión con el campo barrio del dataset listings, permitiendo enriquecer los anuncios con su información territorial.

10.2. Gestión del proyecto: GANTT

Con el fin de organizar internamente al equipo y distribuir los tiempos para abarcar todo el alcance del proyecto, se diseñó un diagrama de GANTT que sirvió como guía y herramienta para cumplir con todos los objetivos del proyecto.

		SEMANA 4	SEMANA 5	SEMANA 6	SEMANA 7	SEMANA 8	SEMANA 9	SEMANA 10
Qué hacemos?	1 - Definición del proyecto	sábado 24/01						
Qué queremos?	2 - Desarrollar análisis (pregunta de negocio)		martes 27/01					
Qué tenemos que hacer?	**PYTHON**							
	3 - Análisis del dataset			Análisis del dataset				
	- Preparación y análisis inicial con Python		31/1/2026 - teórico	3/2/2026 - python	sábado 07/02	jueves 12/02		
	- Análisis por columnas		31/1/2026 - teórico	3/2/2026 - python	sábado 07/02	jueves 12/02		
	- Creación de columnas adicionales		31/1/2026 - teórico	3/2/2026 - python	sábado 07/02	jueves 12/02		
	- Definición de KPIs (indicadores clave)		31/1/2026 - teórico	3/2/2026 - python	sábado 07/02	jueves 12/02		
	- Análisis exploratorio de datos (EDA)			martes 03/02	sábado 07/02	jueves 12/02		
	- Detección de outliers			martes 03/02	sábado 07/02	jueves 12/02		
	- Correlaciones y estadística descriptiva			martes 03/02	sábado 07/02	jueves 12/02		
	- Distribución de variables			martes 03/02	sábado 07/02	jueves 12/02		
	SQL							
	4 - Diseño de base de datos					Diseño de base de datos		
	- Estructura general - tablas					domingo 15/02		
	- Modelo relacional (estrella)					domingo 15/02		
	- Proceso de conexión y carga						martes 17, sábado 21 y martes 24	
	- Validación de integridad						martes 17, sábado 21 y martes 24	
	POWER BI							
	5 - Visualización y análisis final						Dashboard	
	- Objetivo (a qué queremos responder)						sábado 28	
	- Estructura del dashboard						sábado 28	
	- Resumen de KPIs						sábado 28 / martes 3	
	- Validaciones clave						sábado 28 / martes 3	
	6 - Resultados							martes 03 / sábado 7
	7 - Conclusiones y recomendaciones							martes 03 / sábado 7
	- Conclusiones generales							martes 03 / sábado 7
	- Recomendaciones estratégicas							martes 03 / sábado 7
Entregas:	INFORME DETALLADO EN PDF							martes 03 / sábado 7
	PRESENTACIÓN							martes 03 / sábado 7
	CÓDIGO FUENTE							martes 03 / sábado 7
	VIDEO DE PRESENTACIÓN							martes 03 / sábado 7

Para una mejor visualización del GANTT: Gestión del proyecto- GANTT



BMA
BARCELONA
MARKET ANALYTICS